

# 100 câu hỏi phỏng vấn AI ML DL, thị giác máy tính, xử lý ngôn ngữ tự nhiên

June 11, 2024

## 0.0.1 Câu hỏi 1:

**Phỏng vấn viên:** Bạn có thể giải thích sự khác nhau giữa Machine Learning và Deep Learning không?

**Trả lời gợi ý:** Machine Learning (ML) là một nhánh của AI mà trong đó các mô hình học từ dữ liệu để thực hiện các tác vụ. Deep Learning (DL) là một nhánh của ML, sử dụng các mạng neural sâu với nhiều tầng để học từ dữ liệu. Mô hình DL có khả năng xử lý dữ liệu phức tạp và trừu tượng hơn nhờ vào cấu trúc nhiều tầng của nó.

## 0.0.2 Câu hỏi 2:

**Phỏng vấn viên:** Trong các dự án về thị giác máy tính, bạn đã sử dụng TensorFlow và Keras như thế nào?

**Trả lời gợi ý:** Trong các dự án thị giác máy tính của tôi, tôi đã sử dụng TensorFlow và Keras để xây dựng và huấn luyện các mô hình CNN (Convolutional Neural Networks) cho các tác vụ như phân loại hình ảnh, phát hiện đối tượng, và phân đoạn hình ảnh. Tôi đã sử dụng Keras như một API mức cao để dễ dàng xây dựng mô hình, và TensorFlow cho việc tối ưu hóa và triển khai mô hình.

## 0.0.3 Câu hỏi 3:

**Phỏng vấn viên:** Bạn có thể giải thích một số lợi ích của việc sử dụng FastAPI trong các dự án của bạn không?

**Trả lời gợi ý:** FastAPI là một framework web Python nhanh và hiện đại, cung cấp hiệu suất cao nhờ sử dụng ASGI (Asynchronous Server Gateway Interface). Một số lợi ích chính của việc sử dụng FastAPI bao gồm: tốc độ thực thi nhanh, hỗ trợ đầy đủ các tính năng hiện đại của Python như type hints, và khả năng dễ dàng xây dựng các API RESTful mạnh mẽ và hiệu quả.

## 0.0.4 Câu hỏi 4:

**Phỏng vấn viên:** Bạn đã triển khai React và TailwindCSS trong dự án của mình như thế nào?

**Trả lời gợi ý:** Tôi đã sử dụng React để xây dựng giao diện người dùng động và phản hồi nhanh. React giúp quản lý trạng thái và cập nhật giao diện người dùng dựa trên sự thay đổi của dữ liệu. TailwindCSS được sử dụng để thiết kế các giao diện đẹp mắt và nhất quán, nhờ vào hệ thống các lớp tiện ích, giúp tăng tốc độ phát triển và duy trì sự nhất quán trong thiết kế.

### 0.0.5 Câu hỏi 5:

**Phỏng vấn viên:** Bạn có thể giải thích cách mà bạn đã tích hợp MySQL trong các dự án của mình không?

**Trả lời gợi ý:** Tôi đã sử dụng MySQL để quản lý và lưu trữ dữ liệu ứng dụng. Các ứng dụng của tôi sử dụng ORM (Object-Relational Mapping) như SQLAlchemy để giao tiếp với cơ sở dữ liệu, giúp dễ dàng thực hiện các truy vấn và thao tác dữ liệu. MySQL cung cấp một hệ thống quản lý cơ sở dữ liệu mạnh mẽ và hiệu quả cho các ứng dụng của tôi.

### 0.0.6 Câu hỏi 6:

**Phỏng vấn viên:** Bạn có thể mô tả một tình huống cụ thể trong đó bạn đã sử dụng Flask để xây dựng một ứng dụng web không?

**Trả lời gợi ý:** Trong một dự án gần đây, tôi đã sử dụng Flask để xây dựng một ứng dụng web đơn giản cho việc dự đoán giá nhà dựa trên các yếu tố đầu vào của người dùng. Flask giúp tôi dễ dàng tạo ra các route và quản lý yêu cầu HTTP. Tôi đã tích hợp mô hình ML của mình vào Flask để xử lý dự đoán và trả về kết quả cho người dùng qua giao diện web.

### 0.0.7 Câu hỏi 7:

**Phỏng vấn viên:** Bạn có thể giải thích thuật toán Gradient Descent và cách nó được sử dụng trong việc huấn luyện mô hình ML không?

**Trả lời gợi ý:** Gradient Descent là một thuật toán tối ưu hóa dùng để tìm cực tiểu của một hàm mất mát. Trong huấn luyện mô hình ML, Gradient Descent được sử dụng để cập nhật trọng số của mô hình sao cho hàm mất mát được giảm thiểu. Bằng cách tính gradient của hàm mất mát theo các trọng số và điều chỉnh trọng số theo hướng ngược lại của gradient, mô hình sẽ dần dần hội tụ đến giải pháp tối ưu.

### 0.0.8 Câu hỏi 8:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “overfitting” và làm thế nào để tránh nó trong mô hình ML?

**Trả lời gợi ý:** Overfitting xảy ra khi mô hình học quá chi tiết vào dữ liệu huấn luyện, dẫn đến khả năng tổng quát kém khi áp dụng vào dữ liệu mới. Để tránh overfitting, có thể sử dụng các kỹ thuật như regularization (L1, L2), dropout, tăng cường dữ liệu, và cross-validation. Thêm vào đó, chọn một mô hình đơn giản hơn và tăng kích thước tập dữ liệu cũng có thể giúp giảm thiểu overfitting.

### 0.0.9 Câu hỏi 9:

**Phỏng vấn viên:** Bạn có thể giải thích về mạng neural hồi quy (RNN) và khi nào nên sử dụng nó?

**Trả lời gợi ý:** Mạng neural hồi quy (RNN) là một loại mạng neural đặc biệt thích hợp cho việc xử lý dữ liệu tuần tự, như chuỗi thời gian hoặc văn bản. RNN có khả năng ghi nhớ thông tin từ các bước trước trong chuỗi, giúp nó thực hiện tốt trong các tác vụ như dự đoán chuỗi thời gian, dịch máy, và nhận dạng giọng nói. Tuy nhiên, các vấn đề về gradient biến mất có thể xảy ra, và

các biến thể như LSTM (Long Short-Term Memory) hoặc GRU (Gated Recurrent Unit) thường được sử dụng để giải quyết các vấn đề này.

#### 0.0.10 Câu hỏi 10:

**Phỏng vấn viên:** Bạn có thể mô tả quy trình huấn luyện một mô hình LLM (Large Language Model) từ đầu không?

**Trả lời gợi ý:** Quy trình huấn luyện một mô hình LLM bao gồm các bước sau: 1. Thu thập và xử lý dữ liệu: Thu thập một lượng lớn văn bản và tiền xử lý chúng, bao gồm việc làm sạch, token hóa và tạo các cặp input-output cho mô hình. 2. Xây dựng kiến trúc mô hình: Thiết kế kiến trúc mô hình LLM, thường là Transformer-based, với các tầng encoder và decoder. 3. Khởi tạo trọng số: Khởi tạo các trọng số của mô hình. 4. Huấn luyện mô hình: Sử dụng dữ liệu đã chuẩn bị để huấn luyện mô hình qua nhiều epoch, điều chỉnh các tham số mô hình để giảm hàm mất mát. 5. Đánh giá và tinh chỉnh: Đánh giá hiệu suất của mô hình trên tập kiểm tra và thực hiện các tinh chỉnh cần thiết để cải thiện kết quả.

#### 0.0.11 Câu hỏi 11:

**Phỏng vấn viên:** Bạn có thể giải thích sự khác biệt giữa supervised learning và unsupervised learning không?

**Trả lời gợi ý:** Supervised learning là một phương pháp học máy trong đó mô hình được huấn luyện bằng cách sử dụng các cặp dữ liệu đầu vào và đầu ra đã biết. Ví dụ, phân loại email thành spam hoặc không spam. Unsupervised learning, ngược lại, không có các nhãn đầu ra đi kèm với dữ liệu đầu vào. Mục tiêu là tìm kiếm các cấu trúc hoặc mẫu trong dữ liệu, ví dụ như phân cụm (clustering) khách hàng dựa trên hành vi mua sắm.

#### 0.0.12 Câu hỏi 12:

**Phỏng vấn viên:** Bạn có thể mô tả cách hoạt động của một mạng neural tích chập (Convolutional Neural Network - CNN) không?

**Trả lời gợi ý:** CNN là một loại mạng neural đặc biệt cho các tác vụ thị giác máy tính. Nó bao gồm các lớp tích chập (convolutional layers) để tự động phát hiện các đặc trưng trong ảnh, như cạnh, góc, và các mẫu phức tạp hơn. Các lớp tích chập được theo sau bởi các lớp pooling (ví dụ: max-pooling) để giảm kích thước dữ liệu và các lớp fully connected để thực hiện phân loại cuối cùng.

#### 0.0.13 Câu hỏi 13:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “regularization” và nêu một số kỹ thuật regularization phổ biến không?

**Trả lời gợi ý:** Regularization là một tập hợp các kỹ thuật được sử dụng để ngăn chặn overfitting bằng cách làm giảm độ phức tạp của mô hình. Một số kỹ thuật phổ biến bao gồm: - L1 và L2 regularization: Thêm các điều khoản phạt vào hàm mất mát dựa trên giá trị tuyệt đối (L1) hoặc bình phương (L2) của các trọng số. - Dropout: Ngẫu nhiên bỏ qua (drop) một số nút trong quá trình huấn luyện để ngăn chặn sự phụ thuộc quá mức vào các nút cụ thể. - Data augmentation: Tăng cường dữ liệu huấn luyện bằng cách tạo ra các biến thể ngẫu nhiên của dữ liệu hiện có.

#### 0.0.14 Câu hỏi 14:

**Phỏng vấn viên:** Bạn có thể mô tả cách bạn đã triển khai và sử dụng một mô hình học sâu trong một ứng dụng thực tế không?

**Trả lời gợi ý:** Trong một dự án nhận dạng hình ảnh, tôi đã triển khai một mô hình CNN bằng cách sử dụng TensorFlow và Keras để phân loại các loại hoa khác nhau. Sau khi huấn luyện mô hình, tôi đã tích hợp nó vào một ứng dụng web sử dụng Flask và FastAPI. Ứng dụng này cho phép người dùng tải lên hình ảnh và nhận dự đoán loại hoa từ mô hình.

#### 0.0.15 Câu hỏi 15:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “cross-validation” và tại sao nó quan trọng trong ML?

**Trả lời gợi ý:** Cross-validation là một kỹ thuật dùng để đánh giá hiệu suất của một mô hình ML bằng cách chia dữ liệu thành nhiều phần (folds) và huấn luyện và kiểm tra mô hình trên các phần khác nhau. Kỹ thuật này giúp đánh giá khả năng tổng quát hóa của mô hình và tránh overfitting. Một phương pháp phổ biến là k-fold cross-validation, trong đó dữ liệu được chia thành k phần, và mô hình được huấn luyện và kiểm tra k lần trên các tập hợp khác nhau của dữ liệu.

#### 0.0.16 Câu hỏi 16:

**Phỏng vấn viên:** Bạn có thể mô tả cách hoạt động của thuật toán k-means clustering không?

**Trả lời gợi ý:** K-means clustering là một thuật toán phân cụm không giám sát. Nó hoạt động bằng cách phân chia dữ liệu thành k cụm (clusters) dựa trên khoảng cách Euclidean. Quy trình bao gồm: 1. Khởi tạo k điểm trung tâm (centroids) ban đầu. 2. Gán mỗi điểm dữ liệu vào cụm có điểm trung tâm gần nhất. 3. Cập nhật điểm trung tâm của mỗi cụm dựa trên các điểm dữ liệu được gán vào cụm đó. 4. Lặp lại các bước 2 và 3 cho đến khi điểm trung tâm không thay đổi nhiều hoặc đạt đến số vòng lặp tối đa.

#### 0.0.17 Câu hỏi 17:

**Phỏng vấn viên:** Bạn có thể giải thích cách bạn đã sử dụng MySQL để lưu trữ và truy vấn dữ liệu trong một dự án cụ thể không?

**Trả lời gợi ý:** Trong một dự án quản lý thông tin khách hàng, tôi đã sử dụng MySQL để lưu trữ thông tin khách hàng, giao dịch và lịch sử mua sắm. Tôi đã sử dụng SQLAlchemy làm ORM để dễ dàng tương tác với cơ sở dữ liệu từ ứng dụng Flask. Các truy vấn SQL được viết để tìm kiếm và phân tích dữ liệu, ví dụ như tìm kiếm khách hàng theo tên hoặc phân tích xu hướng mua sắm.

#### 0.0.18 Câu hỏi 18:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “epoch”, “batch size”, và “learning rate” trong quá trình huấn luyện mô hình DL không?

**Trả lời gợi ý:** - **Epoch:** Một epoch là một lượt qua toàn bộ tập dữ liệu huấn luyện. Trong quá trình huấn luyện, mô hình sẽ trải qua nhiều epoch để cải thiện hiệu suất. - **Batch size:** Số lượng mẫu dữ liệu được sử dụng trong một lần cập nhật trọng số của mô hình. Batch size lớn sẽ giảm số lần cập nhật nhưng tăng khối lượng tính toán mỗi lần, trong khi batch size nhỏ sẽ làm ngược lại. - **Learning rate:** Tốc độ học của mô hình, quyết định mức độ điều chỉnh các trọng số trong mỗi

bước cập nhật. Learning rate quá cao có thể làm mất tính ổn định của mô hình, còn quá thấp có thể làm quá trình huấn luyện chậm chạp.

#### 0.0.19 Câu hỏi 19:

**Phỏng vấn viên:** Bạn có thể giải thích cách bạn đã triển khai một pipeline ML từ đầu đến cuối không?

**Trả lời gợi ý:** Trong một dự án dự đoán giá nhà, tôi đã triển khai một pipeline ML bao gồm các bước sau: 1. **Thu thập dữ liệu:** Thu thập dữ liệu từ nhiều nguồn khác nhau. 2. **Tiền xử lý dữ liệu:** Làm sạch và biến đổi dữ liệu, bao gồm việc xử lý các giá trị thiếu, chuẩn hóa dữ liệu và tạo ra các đặc trưng mới. 3. **Xây dựng mô hình:** Chọn mô hình phù hợp, ví dụ như Linear Regression hoặc Random Forest, và huấn luyện mô hình với dữ liệu đã xử lý. 4. **Đánh giá mô hình:** Sử dụng các kỹ thuật cross-validation và các chỉ số đánh giá như MAE, RMSE để đánh giá hiệu suất của mô hình. 5. **Triển khai mô hình:** Đưa mô hình vào sản xuất bằng cách sử dụng Flask và FastAPI để tạo API cho các dự đoán trong thời gian thực.

#### 0.0.20 Câu hỏi 20:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của thuật toán Support Vector Machine (SVM) không?

**Trả lời gợi ý:** SVM là một thuật toán học máy giám sát được sử dụng cho các tác vụ phân loại và hồi quy. Nó hoạt động bằng cách tìm kiếm siêu phẳng (hyperplane) tốt nhất để phân tách các lớp dữ liệu trong không gian đặc trưng. SVM tối ưu hóa khoảng cách giữa các điểm dữ liệu gần nhất của mỗi lớp (gọi là margin). Trong trường hợp dữ liệu không thể phân tách tuyến tính, SVM sử dụng các hạt nhân (kernels) để ánh xạ dữ liệu vào không gian chiều cao hơn, nơi dữ liệu có thể được phân tách tuyến tính.

#### 0.0.21 Câu hỏi 21:

**Phỏng vấn viên:** Bạn có thể giải thích sự khác biệt giữa ReLU và Sigmoid activation function không?

**Trả lời gợi ý:** ReLU (Rectified Linear Unit) và Sigmoid là hai hàm kích hoạt phổ biến trong mạng neural. ReLU cho đầu ra bằng giá trị đầu vào nếu đầu vào lớn hơn 0, và bằng 0 nếu không. ReLU giúp giải quyết vấn đề gradient biến mất và thường được sử dụng trong các mạng neural sâu. Sigmoid, ngược lại, biến đổi giá trị đầu vào thành một giá trị giữa 0 và 1, giúp mô hình dễ dàng xử lý các bài toán phân loại nhị phân. Tuy nhiên, Sigmoid có thể gặp phải vấn đề gradient biến mất do độ dốc của nó nhỏ khi giá trị đầu vào lớn hoặc nhỏ.

#### 0.0.22 Câu hỏi 22:

**Phỏng vấn viên:** Bạn có thể mô tả các bước cần thiết để triển khai một mô hình học máy lên môi trường sản xuất không?

**Trả lời gợi ý:** Để triển khai một mô hình học máy lên môi trường sản xuất, các bước thường bao gồm: 1. **Chuẩn bị mô hình:** Huấn luyện và lưu trữ mô hình đã huấn luyện. 2. **Xây dựng API:** Sử dụng các framework như Flask hoặc FastAPI để xây dựng API cung cấp các dự đoán từ mô hình. 3. **Containerization:** Sử dụng Docker để đóng gói ứng dụng và các phụ thuộc của nó, đảm bảo tính di động và nhất quán. 4. **Triển khai:** Sử dụng các công cụ như Kubernetes hoặc

các dịch vụ đám mây như AWS, GCP để triển khai container lên môi trường sản xuất. 5. **Giám sát:** Thiết lập các hệ thống giám sát để theo dõi hiệu suất và độ chính xác của mô hình, và xử lý các vấn đề phát sinh.

#### 0.0.23 Câu hỏi 23:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “dropout” và tầm quan trọng của nó trong DL không?

**Trả lời gợi ý:** Dropout là một kỹ thuật regularization được sử dụng để ngăn chặn overfitting trong mạng neural. Trong quá trình huấn luyện, dropout ngẫu nhiên bỏ qua (drop) một số nút (neuron) trong mạng, với một xác suất nhất định, mỗi lần cập nhật trọng số. Điều này ngăn chặn mạng phụ thuộc quá mức vào một số nút cụ thể và giúp mô hình học được các đặc trưng tổng quát hơn từ dữ liệu.

#### 0.0.24 Câu hỏi 24:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “data augmentation” và tại sao nó quan trọng không?

**Trả lời gợi ý:** Data augmentation là một kỹ thuật được sử dụng để tăng cường tập dữ liệu huấn luyện bằng cách tạo ra các biến thể mới từ dữ liệu hiện có. Trong thị giác máy tính, các kỹ thuật data augmentation phổ biến bao gồm xoay, lật, thay đổi độ sáng, cắt ảnh, và thêm nhiễu. Data augmentation giúp mô hình học được nhiều đặc trưng hơn từ dữ liệu, làm giảm khả năng overfitting và cải thiện khả năng tổng quát hóa của mô hình.

#### 0.0.25 Câu hỏi 25:

**Phỏng vấn viên:** Bạn có thể giải thích về thuật toán PCA (Principal Component Analysis) và ứng dụng của nó trong ML không?

**Trả lời gợi ý:** PCA là một kỹ thuật giảm chiều dữ liệu dùng để tìm các hướng chính (principal components) trong không gian đặc trưng, mà tại đó dữ liệu có độ biến thiên lớn nhất. PCA giúp giảm số chiều của dữ liệu trong khi vẫn giữ được phần lớn thông tin, làm cho việc huấn luyện mô hình nhanh hơn và hiệu quả hơn. Ứng dụng của PCA bao gồm giảm chiều dữ liệu cho các mô hình ML, nén dữ liệu, và trực quan hóa dữ liệu.

#### 0.0.26 Câu hỏi 26:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của thuật toán k-Nearest Neighbors (k-NN) không?

**Trả lời gợi ý:** k-NN là một thuật toán học máy đơn giản và không tham số, dùng cho các tác vụ phân loại và hồi quy. Đối với phân loại, k-NN tìm k điểm dữ liệu gần nhất trong không gian đặc trưng và phân loại điểm dữ liệu mới dựa trên đa số các nhãn của k điểm dữ liệu gần nhất. Đối với hồi quy, giá trị của điểm dữ liệu mới được tính bằng trung bình của k giá trị gần nhất. Khoảng cách giữa các điểm thường được tính bằng khoảng cách Euclidean.

#### 0.0.27 Câu hỏi 27:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “hyperparameter tuning” và các phương pháp thường được sử dụng không?

**Trả lời gợi ý:** Hyperparameter tuning là quá trình điều chỉnh các tham số không học được (hyperparameters) của mô hình để tối ưu hóa hiệu suất của nó. Các phương pháp phổ biến bao gồm: - Grid Search: Thử tất cả các kết hợp có thể của các giá trị hyperparameter trong một lưới (grid). - Random Search: Thử ngẫu nhiên các kết hợp của các giá trị hyperparameter. - Bayesian Optimization: Sử dụng các mô hình xác suất để chọn các hyperparameter tối ưu, thường hiệu quả hơn grid search và random search.

#### 0.0.28 Câu hỏi 28:

**Phỏng vấn viên:** Bạn có thể mô tả kiến trúc của một mô hình Transformer không?

**Trả lời gợi ý:** Transformer là một kiến trúc mạng neural dựa trên cơ chế attention. Nó bao gồm hai phần chính: Encoder và Decoder. - **Encoder:** Gồm nhiều lớp, mỗi lớp bao gồm một cơ chế self-attention và một feed-forward neural network. Encoder nhận đầu vào là một chuỗi và tạo ra một chuỗi các biểu diễn trung gian. - **Decoder:** Gồm nhiều lớp tương tự, nhưng mỗi lớp có thêm một cơ chế attention nữa để chú ý đến đầu ra của encoder. Decoder tạo ra đầu ra là một chuỗi dựa trên chuỗi đầu vào và thông tin từ encoder. Transformer rất hiệu quả trong các tác vụ như dịch máy, tóm tắt văn bản và tạo văn bản.

#### 0.0.29 Câu hỏi 29:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “batch normalization” và lợi ích của nó trong DL không?

**Trả lời gợi ý:** Batch normalization là một kỹ thuật nhằm cải thiện quá trình huấn luyện của mạng neural bằng cách chuẩn hóa các đầu ra của mỗi lớp theo một phân phối chuẩn. Nó giúp tăng tốc độ huấn luyện, ổn định quá trình huấn luyện và làm giảm sự phụ thuộc vào việc khởi tạo trọng số. Batch normalization cũng có tác dụng như một hình thức regularization, giúp giảm overfitting.

#### 0.0.30 Câu hỏi 30:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của thuật toán Gradient Boosting và ứng dụng của nó không?

**Trả lời gợi ý:** Gradient Boosting là một thuật toán ensemble dùng để tạo ra một mô hình mạnh bằng cách kết hợp nhiều mô hình yếu, thường là các cây quyết định (decision trees). Quá trình bao gồm việc huấn luyện mô hình mới để sửa các lỗi của mô hình hiện tại. Cụ thể, Gradient Boosting tối ưu hóa một hàm mất mát bằng cách sử dụng gradient descent. Ứng dụng của Gradient Boosting bao gồm các tác vụ như phân loại, hồi quy và xếp hạng, và các biến thể như XGBoost và LightGBM thường được sử dụng trong các cuộc thi ML và sản xuất.

#### 0.0.31 Câu hỏi 31:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “transfer learning” và một ví dụ ứng dụng của nó trong DL không?

**Trả lời gợi ý:** Transfer learning là kỹ thuật sử dụng một mô hình đã được huấn luyện trên một tập dữ liệu lớn và đa dạng, sau đó tùy chỉnh mô hình này cho một tác vụ cụ thể khác bằng cách huấn luyện tiếp trên một tập dữ liệu nhỏ hơn. Một ví dụ phổ biến là sử dụng các mô hình CNN như VGG, ResNet đã được huấn luyện trên ImageNet để phân loại hình ảnh mới bằng cách thay thế và huấn luyện lại các lớp cuối cùng của mô hình.

### 0.0.32 Câu hỏi 32:

**Phỏng vấn viên:** Bạn có thể giải thích sự khác biệt giữa “precision” và “recall” trong đánh giá mô hình không?

**Trả lời gợi ý:** Precision là tỷ lệ chính xác của các dự đoán dương tính mà thực sự là dương tính ( $TP / (TP + FP)$ ), trong khi recall là tỷ lệ các dương tính thực sự được mô hình phát hiện ( $TP / (TP + FN)$ ). Precision tập trung vào việc giảm thiểu các dự đoán dương tính sai (false positives), còn recall tập trung vào việc giảm thiểu các dự đoán âm tính sai (false negatives). Tùy thuộc vào bài toán cụ thể, trọng số của precision và recall có thể khác nhau.

### 0.0.33 Câu hỏi 33:

**Phỏng vấn viên:** Bạn có thể giải thích về khái niệm “embedding” và ứng dụng của nó trong xử lý ngôn ngữ tự nhiên (NLP) không?

**Trả lời gợi ý:** Embedding là kỹ thuật biểu diễn các từ hoặc thực thể dưới dạng các vector trong không gian nhiều chiều. Các vector này thể hiện ngữ nghĩa và mối quan hệ giữa các từ trong ngữ cảnh. Một ví dụ phổ biến là Word2Vec, trong đó các từ có ngữ nghĩa tương tự sẽ có vector gần nhau. Embedding giúp các mô hình NLP xử lý và hiểu ngữ nghĩa của từ ngữ trong văn bản, được sử dụng trong các tác vụ như phân loại văn bản, dịch máy, và tạo văn bản.

### 0.0.34 Câu hỏi 34:

**Phỏng vấn viên:** Bạn có thể giải thích về khái niệm “attention mechanism” và tầm quan trọng của nó trong DL không?

**Trả lời gợi ý:** Attention mechanism là một kỹ thuật cho phép mô hình tập trung vào các phần quan trọng của đầu vào khi thực hiện dự đoán. Nó tính toán trọng số cho mỗi phần của đầu vào dựa trên mức độ liên quan của chúng với nhiệm vụ hiện tại. Attention mechanism rất quan trọng trong các mô hình như Transformer, giúp cải thiện hiệu suất trong các tác vụ như dịch máy, tóm tắt văn bản, và nhận dạng giọng nói bằng cách cho phép mô hình xử lý các phụ thuộc dài và mối quan hệ phức tạp trong dữ liệu.

### 0.0.35 Câu hỏi 35:

**Phỏng vấn viên:** Bạn có thể giải thích về khái niệm “generative adversarial network” (GAN) và cách nó hoạt động không?

**Trả lời gợi ý:** GAN là một kiến trúc mạng neural bao gồm hai mạng: một generator và một discriminator. Generator tạo ra các mẫu dữ liệu giả từ nhiễu ngẫu nhiên, trong khi discriminator cố gắng phân biệt giữa mẫu dữ liệu thật và giả. Hai mạng này được huấn luyện cùng nhau trong một trò chơi có tổng bằng không, với mục tiêu của generator là làm cho discriminator không thể phân biệt được giữa dữ liệu thật và giả. GAN được sử dụng rộng rãi trong các ứng dụng như tạo hình ảnh, video, và dữ liệu văn bản giả.

### 0.0.36 Câu hỏi 36:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “feature scaling” và tại sao nó quan trọng trong ML không?



**Trả lời gợi ý:** Feature scaling là quá trình chuẩn hóa các đặc trưng để chúng có cùng thang đo, giúp các thuật toán ML hoạt động hiệu quả hơn. Các phương pháp phổ biến bao gồm Min-Max scaling (biến đổi giá trị về khoảng từ 0 đến 1) và Z-score normalization (biến đổi giá trị về trung bình 0 và độ lệch chuẩn 1). Feature scaling quan trọng vì nhiều thuật toán ML dựa vào khoảng cách giữa các điểm dữ liệu, như SVM và k-NN, và các đặc trưng có thang đo lớn hơn có thể chiếm ưu thế so với các đặc trưng khác nếu không được chuẩn hóa.

#### 0.0.37 Câu hỏi 37:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của thuật toán Decision Tree và một số ưu nhược điểm của nó không?

**Trả lời gợi ý:** Decision Tree là một thuật toán học máy giám sát dùng để phân loại và hồi quy. Nó hoạt động bằng cách chia dữ liệu thành các nút dựa trên các điều kiện về giá trị của đặc trưng, với mục tiêu là tạo ra các nút con có độ thuần nhất cao nhất. Ưu điểm của Decision Tree bao gồm dễ hiểu và giải thích, khả năng xử lý cả dữ liệu dạng số và danh mục, và ít yêu cầu tiền xử lý. Nhược điểm bao gồm khả năng overfitting nếu cây quá sâu, và độ nhạy cao với các biến động nhỏ trong dữ liệu.

#### 0.0.38 Câu hỏi 38:

**Phỏng vấn viên:** Bạn có thể giải thích về khái niệm “backpropagation” và vai trò của nó trong việc huấn luyện mạng neural không?

**Trả lời gợi ý:** Backpropagation là thuật toán dùng để cập nhật trọng số của mạng neural bằng cách lan truyền ngược gradient của hàm mất mát qua các tầng của mạng. Quy trình bao gồm hai giai đoạn chính: forward pass (tính toán giá trị đầu ra của mạng) và backward pass (tính toán gradient của hàm mất mát theo từng trọng số và cập nhật trọng số). Backpropagation là nền tảng của việc huấn luyện mạng neural, giúp điều chỉnh các trọng số để giảm thiểu hàm mất mát và cải thiện hiệu suất của mô hình.

#### 0.0.39 Câu hỏi 39:

**Phỏng vấn viên:** Bạn có thể giải thích sự khác biệt giữa “classification” và “regression” trong ML không?

**Trả lời gợi ý:** Classification là một loại bài toán ML trong đó mục tiêu là dự đoán nhãn hoặc lớp của một mẫu dữ liệu, ví dụ như phân loại email thành spam hoặc không spam. Regression, ngược lại, là bài toán dự đoán một giá trị liên tục, ví dụ như dự đoán giá nhà dựa trên các đặc trưng như diện tích và vị trí. Classification thường sử dụng các thuật toán như SVM, k-NN, và Logistic Regression, trong khi Regression thường sử dụng Linear Regression và các biến thể của nó.

#### 0.0.40 Câu hỏi 40:

**Phỏng vấn viên:** Bạn có thể mô tả một tình huống cụ thể trong đó bạn đã sử dụng Flask để xây dựng một RESTful API không?

**Trả lời gợi ý:** Trong một dự án dự đoán giá cổ phiếu, tôi đã sử dụng Flask để xây dựng một RESTful API cho phép người dùng gửi các yêu cầu dự đoán giá cổ phiếu dựa trên các đặc trưng đầu vào như ngày tháng, khối lượng giao dịch, và các chỉ số tài chính. Flask giúp tôi dễ dàng tạo các route để nhận yêu cầu GET và POST, xử lý dữ liệu đầu vào, gọi mô hình dự đoán đã được

huấn luyện, và trả về kết quả dưới dạng JSON. Tôi cũng đã sử dụng Flask để triển khai API này lên một máy chủ đám mây, cho phép người dùng truy cập từ xa.

#### 0.0.41 Câu hỏi 41:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của thuật toán K-means clustering không?

**Trả lời gợi ý:** K-means clustering là một thuật toán unsupervised learning dùng để phân nhóm dữ liệu thành các cụm (clusters) dựa trên đặc trưng của chúng. Quá trình bao gồm ba bước chính: 1. **Khởi tạo centroids:** Chọn ngẫu nhiên K điểm làm centroids ban đầu. 2. **Gán các điểm dữ liệu vào các clusters:** Tính toán khoảng cách giữa mỗi điểm dữ liệu và các centroids, sau đó gán điểm vào cluster có centroid gần nhất. 3. **Cập nhật centroids:** Tính toán lại vị trí của centroids bằng cách lấy trung bình của tất cả các điểm trong cluster tương ứng. Quá trình này lặp lại cho đến khi không có sự thay đổi đáng kể nào trong việc gán các điểm dữ liệu vào các clusters.

#### 0.0.42 Câu hỏi 42:

**Phỏng vấn viên:** Bạn có thể giải thích sự khác biệt giữa “overfitting” và “underfitting” trong ML không?

**Trả lời gợi ý:** Overfitting là hiện tượng mô hình học máy hoạt động quá tốt trên dữ liệu huấn luyện nhưng không thể tổng quát hóa tốt trên dữ liệu mới, trong khi underfitting là hiện tượng mô hình không thể học được đặc điểm cơ bản của dữ liệu và hiệu suất của nó còn kém trên cả dữ liệu huấn luyện lẫn dữ liệu mới. Overfitting thường xảy ra khi mô hình quá phức tạp và có quá nhiều tham số, trong khi underfitting thường xảy ra khi mô hình quá đơn giản và không đủ phức tạp để mô phỏng dữ liệu.

#### 0.0.43 Câu hỏi 43:

**Phỏng vấn viên:** Bạn có thể nói về một số kỹ thuật khắc phục overfitting trong ML không?

**Trả lời gợi ý:** Một số kỹ thuật phổ biến để khắc phục overfitting trong ML bao gồm: - **Regularization:** Thêm một thành phần regularization vào hàm mất mát, như L1 regularization (Lasso) hoặc L2 regularization (Ridge), để kiểm soát độ lớn của các trọng số. - **Cross-validation:** Sử dụng kỹ thuật cross-validation để đánh giá hiệu suất của mô hình trên các tập dữ liệu kiểm tra khác nhau và chọn ra mô hình có hiệu suất tổng quát tốt nhất. - **Dropout:** Áp dụng kỹ thuật dropout trong các mạng neural để ngẫu nhiên loại bỏ một số nút trong quá trình huấn luyện, giúp mô hình tránh overfitting. - **Early stopping:** Dừng quá trình huấn luyện khi hiệu suất của mô hình trên tập kiểm tra bắt đầu giảm, để tránh việc mô hình tiếp tục cải thiện trên dữ liệu huấn luyện nhưng không tổng quát hóa được.

#### 0.0.44 Câu hỏi 44:

**Phỏng vấn viên:** Bạn có thể giải thích sự khác biệt giữa “online learning” và “batch learning” không?

**Trả lời gợi ý:** Trong online learning, mô hình được cập nhật mỗi khi có dữ liệu mới đến, mà không cần phải lưu trữ toàn bộ dữ liệu huấn luyện. Trong batch learning, mô hình được huấn luyện trên toàn bộ dữ liệu huấn luyện một lần duy nhất, sau đó cập nhật trọng số của mô hình dựa trên kết quả tổng hợp từ tất cả dữ liệu. Online learning thường được sử dụng khi dữ liệu liên tục đến và

cần phải cập nhật mô hình liên tục, trong khi batch learning thường được sử dụng khi dữ liệu có sẵn trước và không thay đổi.

#### 0.0.45 Câu hỏi 45:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của thuật toán Support Vector Machine (SVM) không?

**Trả lời gợi ý:** Support Vector Machine (SVM) là một thuật toán học máy dùng để phân loại và hồi quy. Ý tưởng chính của SVM là tìm ra một ranh giới quyết định tốt nhất giữa các lớp dữ liệu bằng cách tìm ra siêu phẳng (hyperplane) có margin lớn nhất giữa các điểm dữ liệu gần nhất của các lớp. Quá trình này thường dựa trên việc tối ưu hóa một hàm mất mát có ràng buộc về margin và sử dụng kỹ thuật kernel để ánh xạ dữ liệu vào một không gian chiều cao hơn nếu cần thiết.

#### 0.0.46 Câu hỏi 46:

**Phỏng vấn viên:** Bạn có thể giải thích ý nghĩa của “kernel trong SVM” không? **Trả lời:** Kernel trong SVM là một phần quan trọng của thuật toán SVM, cho phép ánh xạ dữ liệu từ không gian ban đầu vào một không gian chiều cao hơn, giúp tạo ra một ranh giới quyết định phân chia dữ liệu phức tạp. Có một số loại kernel phổ biến được sử dụng trong SVM, bao gồm Linear Kernel, Polynomial Kernel, Gaussian RBF Kernel, và Sigmoid Kernel. Mỗi loại kernel có cách tính toán độ tương đồng (similarity) giữa các điểm dữ liệu khác nhau và ảnh hưởng đến hiệu suất của mô hình SVM.

#### 0.0.47 Câu hỏi 47:

**Phỏng vấn viên:** Bạn có thể nói về một số phương pháp giảm chiều dữ liệu phổ biến trong Machine Learning không? **Trả lời:** Có nhiều phương pháp giảm chiều dữ liệu được sử dụng trong Machine Learning, bao gồm: - Principal Component Analysis (PCA) - t-SNE (t-distributed Stochastic Neighbor Embedding) - Linear Discriminant Analysis (LDA) - Autoencoders - Feature selection techniques like Recursive Feature Elimination (RFE) và SelectKBest.

Mỗi phương pháp này có ưu điểm và hạn chế riêng, và lựa chọn phương pháp phù hợp phụ thuộc vào bản chất của dữ liệu và mục tiêu của bài toán.

#### 0.0.48 Câu hỏi 48:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của một mạng neural tích chập (CNN) không? **Trả lời:** Mạng neural tích chập (CNN) là một loại mạng neural được thiết kế đặc biệt cho việc xử lý dữ liệu có cấu trúc ruỗng như hình ảnh. CNN sử dụng các tầng tích chập để trích xuất các đặc trưng cục bộ từ dữ liệu và các tầng gộp (pooling layer) để giảm kích thước của dữ liệu. Quá trình này giúp mạng CNN tự động học được các đặc trưng cấp cao từ dữ liệu thô, giúp cải thiện hiệu suất của mô hình trong các tác vụ như phân loại và phát hiện đối tượng trong hình ảnh.

#### 0.0.49 Câu hỏi 49:

**Phỏng vấn viên:** Bạn đã từng sử dụng phương pháp nào để xử lý dữ liệu bị mất mát (missing data) trong Machine Learning? **Trả lời:** Để xử lý dữ liệu bị mất mát trong Machine Learning, có một số phương pháp phổ biến như: - Xóa các mẫu dữ liệu chứa giá trị bị mất mát. - Sử dụng giá trị trung bình hoặc trung vị của đặc trưng để điền vào các giá trị bị mất mát. - Sử dụng mô hình dự đoán để dự đoán các giá trị bị mất mát dựa trên các giá trị đã biết.

Lựa chọn phương pháp phù hợp phụ thuộc vào tỷ lệ giá trị bị mất mát, bản chất của dữ liệu và mục tiêu của bài toán.

#### 0.0.50 Câu hỏi 50:

**Phỏng vấn viên:** Bạn có thể trình bày một số cách để đánh giá hiệu suất của một mô hình học máy không? **Trả lời:** Để đánh giá hiệu suất của một mô hình học máy, có một số phương pháp được sử dụng như: - Accuracy: Tỷ lệ số lượng dự đoán đúng trên tổng số lượng dự đoán. - Precision và Recall: Đánh giá hiệu suất của mô hình trong việc dự đoán các lớp dương tính và âm tính. - F1-score: Trung bình điều hòa giữa precision và recall. - Confusion Matrix: Bảng thống kê hiển thị số lượng dự đoán đúng và sai của mô hình trên mỗi lớp. - ROC Curve và AUC: Đánh giá hiệu suất của mô hình dựa trên tỷ lệ True Positive Rate và False Positive Rate.

Lựa chọn phương pháp đánh giá phù hợp phụ thuộc vào loại dữ liệu và mục tiêu của bài toán.

#### 0.0.51 Câu hỏi 51:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của thuật toán Random Forest không?

**Trả lời:** Thuật toán Random Forest là một phương pháp học máy dựa trên việc xây dựng nhiều cây quyết định (decision trees) khác nhau và kết hợp kết quả từ chúng để ra quyết định cuối cùng. Quá trình này bắt đầu bằng việc chọn một số lượng mẫu ngẫu nhiên từ tập dữ liệu huấn luyện để huấn luyện mỗi cây quyết định, sau đó kết hợp kết quả từ các cây để ra quyết định cuối cùng. Random Forest thường cho hiệu suất tốt trên nhiều loại dữ liệu khác nhau và có khả năng xử lý overfitting tốt hơn so với một cây quyết định đơn lẻ.

#### 0.0.52 Câu hỏi 52:

**Phỏng vấn viên:** Bạn có thể nói về ưu điểm và nhược điểm của thuật toán K-nearest neighbors (KNN) không?

**Trả lời:** Ưu điểm của thuật toán K-nearest neighbors là đơn giản và dễ hiểu, không cần huấn luyện trước, và có thể áp dụng trên cả dữ liệu có cấu trúc và không có cấu trúc. Tuy nhiên, nhược điểm của KNN là cần phải lưu trữ toàn bộ tập dữ liệu huấn luyện, làm tăng độ phức tạp tính toán khi kích thước dữ liệu lớn, đồng thời yêu cầu chọn một giá trị K phù hợp để cân bằng giữa bias và variance.

#### 0.0.53 Câu hỏi 53:

**Phỏng vấn viên:** Bạn có thể giải thích ý nghĩa của bias và variance trong bài toán học máy không?

**Trả lời:** Trong bài toán học máy, bias đo lường sự chênh lệch giữa giá trị trung bình của dự đoán của mô hình và giá trị thực tế mà chúng ta muốn dự đoán. Variance đo lường sự biến động của dự đoán của mô hình khi dữ liệu đầu vào thay đổi. Một mô hình có bias cao thường làm giảm độ chính xác trên tập dữ liệu huấn luyện, trong khi một mô hình có variance cao thường làm giảm độ chính xác trên các dữ liệu mới.

#### 0.0.54 Câu hỏi 54:

**Phỏng vấn viên:** Bạn đã từng sử dụng kỹ thuật nào để xử lý vấn đề class imbalance trong bài toán phân loại không?

**Trả lời:** Để xử lý vấn đề class imbalance trong bài toán phân loại, tôi đã sử dụng các kỹ thuật như: - Tăng cường dữ liệu cho lớp thiểu số (data augmentation). - Sử dụng thuật toán SMOTE (Synthetic Minority Over-sampling Technique) để tạo dữ liệu nhân tạo cho lớp thiểu số. - Sử dụng các thuật toán học máy có khả năng xử lý class imbalance như XGBoost hoặc thuật toán SVC với `class_weight='balanced'`.

#### 0.0.55 Câu hỏi 55:

**Phỏng vấn viên:** Bạn có thể giải thích ý nghĩa của ROC Curve và AUC trong đánh giá mô hình phân loại không?

**Trả lời:** ROC Curve là một đồ thị biểu diễn tỷ lệ True Positive Rate (TPR) so với False Positive Rate (FPR) ở các ngưỡng quyết định khác nhau. Đường cong ROC giúp đánh giá hiệu suất của mô hình phân loại trên toàn bộ phạm vi của các ngưỡng quyết định. AUC (Area Under Curve) là diện tích nằm dưới đường cong ROC, cung cấp một phép đo tổng thể về hiệu suất của mô hình, trong đó giá trị AUC càng gần 1 thì mô hình càng tốt. ROC Curve và AUC thường được sử dụng để so sánh hiệu suất giữa các mô hình phân loại khác nhau.

#### 0.0.56 Câu hỏi 56:

**Phỏng vấn viên:** Bạn có thể giải thích khái niệm “bagging” và “boosting” trong Machine Learning không?

**Trả lời:** Bagging (Bootstrap Aggregating) và Boosting là hai kỹ thuật ensemble learning phổ biến trong Machine Learning. - Bagging: Kỹ thuật này tạo ra nhiều mô hình base khác nhau bằng cách huấn luyện trên các tập dữ liệu con được lấy mẫu tái chọn từ tập dữ liệu huấn luyện ban đầu. Sau đó, kết quả của tất cả các mô hình base được kết hợp lại thông qua việc trung bình hoặc đa số phiếu bầu để ra quyết định cuối cùng. - Boosting: Kỹ thuật này tạo ra một chuỗi các mô hình base theo cách tuần tự, trong đó mỗi mô hình cố gắng cải thiện những điểm yếu của các mô hình trước đó. Các mô hình base sau đó được kết hợp thông qua việc tăng cường trọng số cho các điểm dữ liệu mà các mô hình trước đó dự đoán sai, từ đó tạo ra một mô hình mạnh hơn.

#### 0.0.57 Câu hỏi 57:

**Phỏng vấn viên:** Bạn có thể nói về các thuật toán học máy phổ biến dùng để xử lý dữ liệu chuỗi thời gian không?

**Trả lời:** Có một số thuật toán học máy được sử dụng để xử lý dữ liệu chuỗi thời gian, bao gồm: - ARIMA (Autoregressive Integrated Moving Average) - SARIMA (Seasonal ARIMA) - LSTM (Long Short-Term Memory) - Prophet (được phát triển bởi Facebook) - XGBoost và LightGBM với tính năng mở rộng để xử lý dữ liệu chuỗi thời gian.

Mỗi thuật toán có ưu điểm và hạn chế riêng, và lựa chọn phụ thuộc vào bản chất của dữ liệu và mục tiêu của bài toán.

#### 0.0.58 Câu hỏi 58:

**Phỏng vấn viên:** Bạn có thể giải thích ý nghĩa của “feature scaling” trong Machine Learning không?

**Trả lời:** Feature scaling là quá trình chuẩn hóa dữ liệu đầu vào của mô hình để đảm bảo rằng các đặc trưng có cùng phạm vi giá trị, giúp mô hình học tốt hơn và hội tụ nhanh hơn. Phổ biến nhất

là Min-Max Scaling và Standardization. Min-Max Scaling đưa giá trị của mỗi đặc trưng về một phạm vi cụ thể, thường là từ 0 đến 1. Standardization đưa giá trị của mỗi đặc trưng về trung bình là 0 và độ lệch chuẩn là 1.

#### 0.0.59 Câu hỏi 59:

**Phỏng vấn viên:** Bạn có thể giải thích ý nghĩa của “hyperparameter tuning” trong quá trình huấn luyện mô hình Machine Learning không?

**Trả lời:** Hyperparameter tuning là quá trình tìm kiếm các giá trị tối ưu cho các siêu tham số (hyperparameters) của mô hình học máy, như là learning rate, số lượng cây trong một RandomForest, hoặc số lượng lớp trong mạng neural. Mục tiêu của hyperparameter tuning là tìm ra bộ siêu tham số tối ưu giúp mô hình có hiệu suất tốt nhất trên tập dữ liệu kiểm tra hoặc dữ liệu mới.

#### 0.0.60 Câu hỏi 60:

**Phỏng vấn viên:** Bạn đã từng sử dụng phương pháp nào để giải quyết vấn đề overfitting trong mô hình học máy không?

**Trả lời:** Để giải quyết vấn đề overfitting trong mô hình học máy, tôi đã sử dụng các kỹ thuật như: - Regularization (L1 và L2) - Dropout trong mạng neural networks - Cross-validation để đánh giá hiệu suất mô hình - Early stopping để dừng quá trình huấn luyện khi hiệu suất trên tập kiểm tra không cải thiện nữa.

#### 0.0.61 Câu hỏi 61:

**Phỏng vấn viên:** Bạn đã từng sử dụng phương pháp nào để xử lý vấn đề “categorical variables” trong Machine Learning?

**Trả lời:** Để xử lý categorical variables trong Machine Learning, tôi đã sử dụng các phương pháp như: - One-Hot Encoding: Chuyển đổi các biến phân loại thành biến nhị phân (0 và 1) cho mỗi giá trị có thể có. - Label Encoding: Chuyển đổi các biến phân loại thành các số nguyên duy nhất. - Categorical Embedding: Biểu diễn các biến phân loại dưới dạng vector có chiều thấp hơn để giảm chiều dữ liệu. Lựa chọn phương pháp phù hợp phụ thuộc vào loại dữ liệu và mục tiêu của bài toán.

#### 0.0.62 Câu hỏi 62:

**Phỏng vấn viên:** Bạn có thể giải thích ý nghĩa của thuật ngữ “cross-validation” không?

**Trả lời:** Cross-validation là một kỹ thuật được sử dụng để đánh giá hiệu suất của mô hình học máy bằng cách chia dữ liệu thành các tập huấn luyện và kiểm tra, sau đó huấn luyện và kiểm tra mô hình trên các tập này nhiều lần. Kỹ thuật này giúp đánh giá hiệu suất của mô hình một cách chính xác hơn bằng cách kiểm tra mô hình trên các dữ liệu mà nó chưa được huấn luyện. Các phương pháp cross-validation phổ biến bao gồm k-Fold Cross-Validation, Leave-One-Out Cross-Validation và Stratified Cross-Validation.

#### 0.0.63 Câu hỏi 63:

**Phỏng vấn viên:** Bạn có thể nói về ưu điểm và nhược điểm của mạng neural tích chập (CNN) so với mạng neural thông thường không?

**Trả lời:** Ưu điểm của mạng neural tích chập (CNN) so với mạng neural thông thường là: - Hiệu suất cao trong việc xử lý dữ liệu có cấu trúc như hình ảnh. - Tự động trích xuất đặc trưng cục bộ từ dữ liệu. - Giảm lượng tham số cần huấn luyện, giảm nguy cơ overfitting.

Nhược điểm của CNN là: - Yêu cầu lượng dữ liệu huấn luyện lớn hơn. - Chi phí tính toán cao hơn đối với dữ liệu lớn. - Có thể khó khăn trong việc giải thích quá trình quyết định của mô hình.

#### 0.0.64 Câu hỏi 64:

**Phỏng vấn viên:** Bạn đã từng sử dụng thuật toán clustering nào trong dự án của mình? Hãy giải thích cách bạn sử dụng nó.

**Trả lời:** Trong dự án của mình, tôi đã sử dụng thuật toán K-means clustering để phân nhóm khách hàng dựa trên hành vi mua hàng. Đầu tiên, tôi tiền xử lý dữ liệu để loại bỏ các giá trị bị thiếu và chuẩn hóa dữ liệu. Sau đó, tôi sử dụng K-means clustering để phân nhóm khách hàng thành các cụm dựa trên các đặc trưng như tổng số tiền mua hàng, số lần mua hàng, và số lượng sản phẩm mua. Cuối cùng, tôi phân tích các nhóm này để hiểu rõ hơn về hành vi mua hàng của từng nhóm và tùy chỉnh chiến lược kinh doanh của công ty.

#### 0.0.65 Câu hỏi 65:

**Phỏng vấn viên:** Bạn đã sử dụng mô hình học sâu nào khác ngoài mạng neural không? Hãy nói về kinh nghiệm của bạn với mô hình đó.

**Trả lời:** Ngoài mạng neural, tôi đã sử dụng mô hình Recurrent Neural Networks (RNNs) trong một dự án về dự đoán chuỗi thời gian. RNNs cho phép mô hình học các mẫu dữ liệu dựa trên chuỗi thời gian và tạo ra dự đoán dựa trên thông tin lịch sử. Tuy nhiên, tôi đã gặp phải vấn đề của sự biến mất của gradient (vanishing gradient) trong quá trình huấn luyện RNNs, do đó, tôi đã thử nghiệm các biến thể của RNNs như LSTM và GRU để giải quyết vấn đề này và cải thiện hiệu suất của mô hình.

#### 0.0.66 Câu hỏi 66:

**Phỏng vấn viên:** Bạn có thể giải thích ý nghĩa của thuật ngữ “dropout” trong mạng neural không?

**Trả lời:** Dropout là một kỹ thuật regularization được sử dụng trong mạng neural networks để giảm overfitting. Trong quá trình huấn luyện, dropout ngẫu nhiên loại bỏ một phần của các đơn vị (neurons) trong mạng neural với một xác suất được thiết lập trước. Kỹ thuật này giúp làm suy giảm mạnh mẽ kết nối giữa các đơn vị và ngăn chặn việc mạng neural học các mẫu dữ liệu cụ thể trong tập huấn luyện, từ đó giảm overfitting và tăng tính tổng quát hóa của mô hình.

#### 0.0.67 Câu hỏi 67:

**Phỏng vấn viên:** Bạn có thể nói về mô hình Generative Adversarial Networks (GANs) không? Và bạn đã sử dụng chúng trong bất kỳ dự án nào chưa?

**Trả lời:** Generative Adversarial Networks (GANs) là một kiến trúc mạng neural được đề xuất bởi Ian Goodfellow và các cộng sự vào năm 2014, gồm hai mạng con: mạng generative (Generative Network) và mạng phân biệt (Discriminative Network), cạnh tranh với nhau thông qua quá trình huấn luyện. Mạng generative cố gắng tạo ra dữ liệu mới từ một phân phối xác suất đã cho, trong khi mạng phân biệt cố gắng phân biệt giữa dữ liệu được tạo ra từ mạng generative và dữ liệu thực.

Tôi đã sử dụng GANs trong một dự án về tạo ra hình ảnh ảo từ dữ liệu thực để tăng cường dữ liệu huấn luyện cho một bài toán nhận dạng đối tượng.

#### 0.0.68 Câu hỏi 68:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của thuật toán Naive Bayes không?

**Trả lời:** Thuật toán Naive Bayes là một phương pháp học máy dựa trên lý thuyết xác suất và được sử dụng chủ yếu trong các bài toán phân loại. Cơ sở của Naive Bayes là Định lý Bayes, nó giả định rằng các đặc trưng đầu vào là độc lập với nhau, điều này có nghĩa là giá trị của một đặc trưng không ảnh hưởng đến giá trị của các đặc trưng khác. Mô hình Naive Bayes tính xác suất của một lớp dựa trên dữ liệu đầu vào bằng cách sử dụng công thức Bayes và giả định Naive Bayes.

#### 0.0.69 Câu hỏi 69:

**Phỏng vấn viên:** Bạn đã từng sử dụng mô hình Autoencoder trong dự án nào chưa? Nếu có, hãy nói về trải nghiệm của bạn.

**Trả lời:** Trong dự án về phân tích dữ liệu hình ảnh, tôi đã sử dụng mô hình Autoencoder để giảm chiều dữ liệu và trích xuất các đặc trưng cần thiết từ dữ liệu hình ảnh. Autoencoder là một loại mạng neural được huấn luyện để sao chép đầu vào vào đầu ra, thông qua một quá trình học các đặc trưng quan trọng từ dữ liệu. Quá trình này giúp giảm chiều dữ liệu mà vẫn giữ lại các đặc trưng quan trọng, từ đó cải thiện hiệu suất của các mô hình học máy khác.

#### 0.0.70 Câu hỏi 70:

**Phỏng vấn viên:** Bạn có thể nói về ưu điểm và nhược điểm của thuật toán Decision Trees không?

**Trả lời:** Ưu điểm của thuật toán Decision Trees là: - Dễ hiểu và dễ giải thích. - Có thể xử lý cả dữ liệu có và không có cấu trúc. - Không cần quá nhiều tiền xử lý dữ liệu. - Cho phép việc tạo ra một mô hình dự đoán non-linear.

Nhược điểm của Decision Trees là: - Dễ bị overfitting, đặc biệt là trên dữ liệu có nhiều đặc trưng. - Khá nhạy cảm với các biến nhỏ trong dữ liệu, dẫn đến sự không ổn định trong mô hình. - Khó khăn trong việc xử lý các vấn đề liên tục (continuous) hoặc có giá trị bị thiếu.

#### 0.0.71 Câu hỏi 71:

**Phỏng vấn viên:** Bạn có thể giải thích cách hoạt động của thuật toán t-SNE không?

**Trả lời:** t-SNE (t-distributed Stochastic Neighbor Embedding) là một thuật toán sử dụng trong việc giảm chiều dữ liệu và biểu diễn dữ liệu đa chiều thành dữ liệu hai chiều hoặc ba chiều để có thể hiển thị được trực quan trên không gian Euclidean. Thuật toán này tập trung vào việc giữ lại các cấu trúc cục bộ của dữ liệu, tức là giữ lại các điểm dữ liệu gần nhau trong không gian cao chiều, giữ lại sự tương tự giữa các điểm, và tách biệt các cụm dữ liệu. t-SNE cố gắng giảm khoảng cách giữa các điểm dữ liệu tương tự và tăng khoảng cách giữa các điểm dữ liệu khác biệt.

#### 0.0.72 Câu hỏi 72:

**Phỏng vấn viên:** Bạn đã từng sử dụng Regularization trong quá trình huấn luyện mô hình học máy chưa? Hãy nói về kinh nghiệm của bạn.



**Trả lời:** Có, tôi đã sử dụng Regularization trong quá trình huấn luyện mô hình học máy để giảm overfitting. Regularization là một kỹ thuật thêm vào hàm mất mát (loss function) một thành phần phạt cho các trọng số lớn trong mô hình, từ đó kiểm soát sự phức tạp của mô hình. Tôi đã thử nghiệm cả L1 regularization (Lasso) và L2 regularization (Ridge) trong các mô hình như Linear Regression và Logistic Regression để giảm overfitting và cải thiện khả năng tổng quát hóa của mô hình.

#### 0.0.73 Câu hỏi 73:

**Phỏng vấn viên:** Bạn có thể nói về ưu điểm và nhược điểm của Support Vector Machines (SVMs) không?

**Trả lời:** Ưu điểm của Support Vector Machines là: - Hiệu suất cao trong các bài toán phân loại dữ liệu tuyến tính và phi tuyến tính. - Khả năng xử lý dữ liệu có số lượng chiều lớn. - Sử dụng một tập hợp nhỏ các điểm dữ liệu hỗ trợ để ra quyết định, do đó tốn ít bộ nhớ. - Có thể tùy chỉnh hàm kernel để mô hình hóa dữ liệu phi tuyến tính.

Nhược điểm của SVMs là: - Đòi hỏi thời gian và tài nguyên tính toán lớn khi áp dụng trên các tập dữ liệu lớn. - Nhạy cảm với sự chọn lựa của các siêu tham số như kernel và C.

#### 0.0.74 Câu hỏi 74:

**Phỏng vấn viên:** Bạn đã từng sử dụng ensemble learning trong dự án của mình chưa? Hãy nói về kinh nghiệm của bạn.

**Trả lời:** Có, tôi đã sử dụng ensemble learning trong nhiều dự án. Một trong những kỹ thuật ensemble learning phổ biến mà tôi đã áp dụng là Random Forest và Gradient Boosting Machines (GBM) như XGBoost và LightGBM. Ensemble learning giúp tăng cường tính tổng quát hóa và giảm overfitting bằng cách kết hợp nhiều mô hình dự đoán khác nhau. Tôi đã thấy rằng việc kết hợp các mô hình này thường mang lại hiệu suất tốt hơn so với việc sử dụng một mô hình đơn lẻ.

#### 0.0.75 Câu hỏi 75:

**Phỏng vấn viên:** Bạn có thể nói về kỹ thuật Bootstrap Resampling và cách nó được sử dụng trong Machine Learning không?

**Trả lời:** Bootstrap Resampling là một kỹ thuật thống kê được sử dụng để ước lượng phân phối của một thống kê mẫu bằng cách lấy mẫu tái chọn từ dữ liệu gốc. Trong Machine Learning, Bootstrap Resampling thường được sử dụng để tạo ra nhiều tập dữ liệu con từ tập dữ liệu huấn luyện ban đầu, từ đó tạo ra nhiều mô hình khác nhau để tạo thành một ensemble. Điều này giúp cải thiện tính tổng quát hóa của mô hình bằng cách giảm variance và ngăn chặn overfitting.

Dĩ nhiên, dưới đây là câu hỏi và câu trả lời cho các câu hỏi từ 76 đến 80:

#### 0.0.76 Câu hỏi 76:

**Phỏng vấn viên:** Bạn có thể nêu ra một ví dụ cụ thể về một dự án AI/ML bạn đã tham gia và cách bạn đã giải quyết một vấn đề khó khăn trong quá trình đó?

**Trả lời:** Trong một dự án nhận diện văn bản từ ảnh, tôi đã đối mặt với một thách thức khi dữ liệu đầu vào chứa nhiều nhiễu và biến dạng. Để giải quyết vấn đề này, tôi đã thực hiện các bước tiền xử lý dữ liệu để loại bỏ nhiễu và chuẩn hóa hình ảnh. Sau đó, tôi đã sử dụng một mạng

neural convolutional (CNN) để trích xuất đặc trưng từ hình ảnh và một mô hình Recurrent Neural Network (RNN) để phân loại các ký tự từ các đặc trưng đã trích xuất. Qua việc kết hợp hai mô hình này cùng với việc điều chỉnh siêu tham số, tôi đã đạt được kết quả chính xác cao trong việc nhận diện văn bản từ ảnh.

#### 0.0.77 Câu hỏi 77:

**Phỏng vấn viên:** Làm thế nào bạn đánh giá hiệu suất của một mô hình học máy và làm thế nào để bạn đối phó khi mô hình không đạt được hiệu suất mong muốn?

**Trả lời:** Để đánh giá hiệu suất của một mô hình học máy, tôi thường sử dụng các phép đo như accuracy, precision, recall, và F1-score trên tập kiểm tra. Ngoài ra, tôi cũng xem xét các đồ thị ROC và Precision-Recall để đánh giá hiệu suất của mô hình trên các ngưỡng quyết định khác nhau. Khi mô hình không đạt được hiệu suất mong muốn, tôi thường điều chỉnh các siêu tham số của mô hình, thử nghiệm các thuật toán khác nhau, hoặc thực hiện tiền xử lý dữ liệu khác để cải thiện hiệu suất của mô hình.

#### 0.0.78 Câu hỏi 78:

**Phỏng vấn viên:** Bạn có kinh nghiệm trong việc làm việc với dữ liệu không cân bằng (imbalanced data) không? Nếu có, bạn đã sử dụng phương pháp nào để xử lý vấn đề này?

**Trả lời:** Trong một dự án phân loại gian lận thẻ tín dụng, tôi đã phải làm việc với dữ liệu không cân bằng vì số lượng giao dịch gian lận chỉ chiếm một phần nhỏ trong tổng số giao dịch. Để xử lý vấn đề này, tôi đã sử dụng kỹ thuật resampling để tăng cường dữ liệu thuộc lớp thiểu số bằng cách tạo thêm các mẫu tổng hợp hoặc tăng cường mẫu (oversampling) và/hoặc loại bỏ mẫu (undersampling) từ lớp đa số.

#### 0.0.79 Câu hỏi 79:

**Phỏng vấn viên:** Làm thế nào bạn đảm bảo tính ổn định và tin cậy của một mô hình AI/ML trong môi trường sản xuất?

**Trả lời:** Để đảm bảo tính ổn định và tin cậy của một mô hình AI/ML trong môi trường sản xuất, tôi thường thực hiện các bước sau: 1. **Kiểm định mô hình:** Tôi thường kiểm định mô hình trên một tập dữ liệu kiểm tra độc lập để đảm bảo rằng mô hình hoạt động tốt trên dữ liệu mới. 2. **Giám sát liên tục:** Tôi thiết lập hệ thống giám sát liên tục để theo dõi hiệu suất của mô hình trong thời gian thực và cảnh báo khi có bất kỳ vấn đề nào xảy ra. 3. **Tối ưu hóa liên tục:** Tôi tiếp tục tối ưu hóa mô hình dựa trên dữ liệu mới và phản hồi từ môi trường sản xuất để đảm bảo rằng mô hình luôn duy trì hiệu suất cao nhất có thể. 4. **Xử lý dữ liệu đầu vào:** Tôi đảm bảo dữ liệu đầu vào cho mô hình luôn được xử lý và chuẩn bị một cách đáng tin cậy để tránh ảnh hưởng tiêu cực đến hiệu suất của mô hình. 5. **Bảo vệ tính bảo mật và quyền riêng tư:** Tôi luôn tuân thủ các quy định về bảo mật và quyền riêng tư và đảm bảo rằng mô hình không gây ra rủi ro cho dữ liệu cá nhân hoặc bất kỳ thông tin nhạy cảm nào khác.

#### 0.0.80 Câu hỏi 80:

**Phỏng vấn viên:** Bạn có kinh nghiệm trong việc làm việc với dữ liệu lớn (big data) không? Nếu có, bạn đã sử dụng công nghệ hoặc kỹ thuật nào để xử lý dữ liệu đó?

**Trả lời:** Có, trong một dự án phân tích dữ liệu từ người dùng trên mạng xã hội, tôi đã phải làm việc với dữ liệu lớn từ hàng triệu người dùng và hàng tỉ bản ghi. Để xử lý dữ liệu này, tôi đã sử dụng công nghệ Big Data như Apache Spark để phân tán xử lý dữ liệu trên nhiều nút máy tính và giảm thiểu thời gian xử lý. Tôi cũng đã thực hiện các kỹ thuật như partitioning và caching để tối ưu hóa hiệu suất của các công việc xử lý dữ liệu. Ngoài ra, tôi đã sử dụng các công cụ và thư viện như Hadoop và Apache Kafka để quản lý và xử lý dữ liệu trên một hệ thống phân tán.

#### **0.0.81 Câu hỏi 81:**

**Phỏng vấn viên:** Bạn đã từng tham gia vào một dự án liên quan đến xử lý ngôn ngữ tự nhiên (NLP) chưa? Nếu có, bạn có thể mô tả một tính huống cụ thể trong dự án đó và cách bạn đã giải quyết nó?

#### **0.0.82 Câu trả lời 81:**

Có, tôi đã tham gia vào một dự án NLP để phân loại các email thành các danh mục khác nhau dựa trên nội dung của chúng. Một thách thức lớn là xử lý văn bản không cấu trúc và không chuẩn, đồng thời tăng cường hiệu suất phân loại. Để giải quyết vấn đề này, tôi đã sử dụng một kết hợp của phương pháp tiền xử lý văn bản (như loại bỏ stopwords, stemming và vectorization) và một mô hình học máy (như Support Vector Machine hoặc Naive Bayes) để phân loại email. Tôi cũng đã thử nghiệm và tinh chỉnh các mô hình word embedding như Word2Vec và GloVe để cải thiện hiệu suất phân loại.

#### **0.0.83 Câu hỏi 82:**

**Phỏng vấn viên:** Bạn đã từng sử dụng mạng neural tích chập (CNN) trong các dự án thị giác máy tính chưa? Nếu có, bạn có thể nêu ra một ví dụ cụ thể và kết quả thu được?

#### **0.0.84 Câu trả lời 82:**

Có, tôi đã sử dụng mạng neural tích chập (CNN) trong một dự án nhận diện khuôn mặt. Trong dự án này, CNN được sử dụng để trích xuất các đặc trưng quan trọng từ ảnh khuôn mặt và phân loại chúng thành các nhãn tương ứng (ví dụ: người, không phải người). Kết quả thu được là một hệ thống nhận diện khuôn mặt có khả năng nhận diện chính xác và nhanh chóng trong nhiều điều kiện ánh sáng và góc chụp khác nhau.

#### **0.0.85 Câu hỏi 83:**

**Phỏng vấn viên:** Bạn đã từng tham gia vào việc triển khai mô hình học máy vào môi trường sản xuất chưa? Nếu có, bạn đã gặp phải những thách thức gì và làm thế nào để bạn vượt qua chúng?

#### **0.0.86 Câu trả lời 83:**

Trong một dự án phát hiện vật thể trong hình ảnh, tôi đã triển khai một mô hình học máy vào môi trường sản xuất. Một trong những thách thức lớn nhất là đảm bảo rằng mô hình hoạt động ổn định và chính xác trên dữ liệu thực tế, không chỉ trên tập dữ liệu huấn luyện. Để vượt qua thách thức này, tôi đã thực hiện kiểm tra và kiểm định mô hình trên dữ liệu thực tế, và tinh chỉnh các siêu tham số của mô hình dựa trên phản hồi từ quá trình triển khai.

#### 0.0.87 Câu hỏi 84:

**Phỏng vấn viên:** Trong dự án thị giác máy tính, bạn đã sử dụng các kỹ thuật như data augmentation chưa? Nếu có, bạn có thể mô tả cách bạn đã sử dụng nó để cải thiện hiệu suất của mô hình không?

#### 0.0.88 Câu trả lời 84:

Trong một dự án nhận diện các loại rác thải trong hình ảnh, tôi đã sử dụng kỹ thuật data augmentation để tăng cường dữ liệu huấn luyện. Cụ thể, tôi đã áp dụng các biến đổi như xoay, phóng to, thu nhỏ và lật ảnh để tạo ra các phiên bản mới của các hình ảnh trong tập huấn luyện. Kết quả là mô hình đã được huấn luyện trên một lượng dữ liệu đa dạng hơn, từ đó cải thiện hiệu suất của mô hình trên các dữ liệu mới và không nhìn thấy trước.

#### 0.0.89 Câu hỏi 85:

**Phỏng vấn viên:** Trong dự án của bạn liên quan đến xử lý ngôn ngữ tự nhiên, bạn đã gặp phải vấn đề không gian từ vựng lớn không? Nếu có, bạn đã sử dụng các kỹ thuật nào để xử lý vấn đề này?

#### 0.0.90 Câu trả lời 85:

Trong một dự án phân loại cảm xúc từ văn bản, tôi đã gặp phải vấn đề với không gian từ vựng lớn khi xử lý các bài viết dài và đa dạng. Để giảm thiểu kích thước của không gian từ vựng, tôi đã sử dụng các kỹ thuật như tokenization, loại bỏ các từ dừng (stopwords), và thực hiện giới hạn kích thước từ.

Dưới đây là 5 câu hỏi và câu trả lời:

#### 0.0.91 Câu hỏi 86:

**Phỏng vấn viên:** Trong dự án thị giác máy tính của bạn, bạn đã sử dụng các mô hình học sâu (deep learning models) như ResNet, Inception, hay EfficientNet chưa? Nếu có, bạn có thể mô tả cách bạn đã tích hợp chúng vào dự án không?

#### 0.0.92 Câu trả lời 86:

Trong dự án nhận diện đối tượng trong video, tôi đã sử dụng mô hình học sâu như ResNet và YOLO (You Only Look Once). Tôi đã tích hợp chúng vào dự án bằng cách sử dụng các thư viện như TensorFlow và Keras để tải và cấu trúc mô hình, sau đó tiến hành huấn luyện trên tập dữ liệu có sẵn.

#### 0.0.93 Câu hỏi 87:

**Phỏng vấn viên:** Trong việc làm việc với dữ liệu hình ảnh, bạn đã gặp phải vấn đề về hiệu suất và tài nguyên không? Nếu có, bạn đã sử dụng các kỹ thuật nào để tăng cường hiệu suất và tiết kiệm tài nguyên?

#### 0.0.94 Câu trả lời 87:

Trong dự án phân loại hình ảnh y tế, tôi đã gặp phải vấn đề về tài nguyên tính toán và hiệu suất khi làm việc với dữ liệu hình ảnh có kích thước lớn. Để giải quyết vấn đề này, tôi đã sử dụng các kỹ thuật như transfer learning để tái sử dụng các mô hình đã được huấn luyện trước đó, cũng như áp dụng kỹ thuật tinh chỉnh siêu tham số để tối ưu hóa hiệu suất mô hình.

#### 0.0.95 Câu hỏi 88:

**Phỏng vấn viên:** Bạn có kinh nghiệm trong việc sử dụng mạng neural dựa trên Attention Mechanism không? Nếu có, bạn có thể mô tả một dự án cụ thể mà bạn đã sử dụng nó không?

#### 0.0.96 Câu trả lời 88:

Có, trong dự án dịch máy, tôi đã sử dụng mạng neural dựa trên Attention Mechanism để cải thiện chất lượng của các bản dịch. Mạng này tập trung vào các phần quan trọng của câu nguồn trong quá trình dịch và thực hiện việc dịch dựa trên những phần đó. Kết quả là, chúng tôi đã thấy cải thiện đáng kể trong chất lượng của các bản dịch so với các phương pháp truyền thống.

#### 0.0.97 Câu hỏi 89:

**Phỏng vấn viên:** Bạn có thể mô tả một kỹ thuật hoặc phương pháp mới bạn đã áp dụng trong một dự án gần đây không?

#### 0.0.98 Câu trả lời 89:

Trong một dự án nhận diện ngôn ngữ cử chỉ từ video, tôi đã sử dụng kỹ thuật 3D Convolutional Neural Networks (CNNs) để trích xuất đặc trưng không gian và thời gian từ dữ liệu video. Kỹ thuật này cho phép mô hình học được các mẫu không gian và thời gian trong dữ liệu video, từ đó cải thiện độ chính xác của việc nhận diện các ngôn ngữ cử chỉ.

Dưới đây là 6 câu hỏi và câu trả lời:

#### 0.0.99 Câu hỏi 90:

**Phỏng vấn viên:** Trong dự án của bạn, bạn đã sử dụng phương pháp nào để xử lý vấn đề overfitting không?

#### 0.0.100 Câu trả lời 90:

Trong dự án phân loại ảnh y tế, để xử lý vấn đề overfitting, tôi đã sử dụng một số kỹ thuật như: - **Regularization:** Áp dụng L1 hoặc L2 regularization vào các layer của mô hình để giảm overfitting. - **Dropout:** Thêm các layer Dropout vào mô hình để ngẫu nhiên loại bỏ một phần các neuron trong quá trình huấn luyện. - **Early Stopping:** Dừng quá trình huấn luyện khi hiệu suất trên tập validation không còn cải thiện nữa. - **Data Augmentation:** Tăng cường dữ liệu huấn luyện bằng cách áp dụng các biến đổi ngẫu nhiên cho ảnh.

#### 0.0.101 Câu hỏi 91:

**Phỏng vấn viên:** Bạn đã từng sử dụng các kỹ thuật như transfer learning chưa? Nếu có, bạn có thể mô tả cách bạn đã áp dụng nó trong dự án không?

#### 0.0.102 Câu trả lời 91:

Có, trong dự án phân loại loài cây từ hình ảnh, tôi đã sử dụng kỹ thuật transfer learning. Cụ thể, tôi đã sử dụng một mô hình đã được huấn luyện trước trên một tập dữ liệu lớn như ImageNet và thay đổi lớp fully connected cuối cùng để phù hợp với số lượng lớp đầu ra của dự án của mình. Sau đó, tôi tiến hành huấn luyện lại mô hình chỉ trên tập dữ liệu nhỏ của dự án.

#### 0.0.103 Câu hỏi 92:

**Phỏng vấn viên:** Trong dự án của bạn, bạn đã sử dụng phương pháp nào để đánh giá hiệu suất của mô hình không?

#### 0.0.104 Câu trả lời 92:

Trong dự án phân loại cảm xúc từ văn bản, tôi đã sử dụng các phép đo như accuracy, precision, recall, và F1-score để đánh giá hiệu suất của mô hình trên tập kiểm tra. Ngoài ra, tôi cũng đã sử dụng ma trận nhầm lẫn (confusion matrix) để xem xét sự phân loại của mô hình trên từng nhãn cụ thể.

#### 0.0.105 Câu hỏi 93:

**Phỏng vấn viên:** Trong dự án của bạn, bạn đã áp dụng phương pháp nào để tăng cường hiệu suất của mô hình không?

#### 0.0.106 Câu trả lời 93:

Trong dự án nhận diện vật thể trong ảnh, tôi đã áp dụng các kỹ thuật sau để tăng cường hiệu suất của mô hình: - **Data Augmentation:** Tăng cường dữ liệu huấn luyện bằng cách áp dụng các biến đổi như xoay, lật ảnh, và phóng to thu nhỏ. - **Transfer Learning:** Sử dụng một mô hình đã được huấn luyện trước trên một tập dữ liệu lớn và tinh chỉnh lại các trọng số cuối cùng cho dự án cụ thể. - **Ensemble Learning:** Kết hợp nhiều mô hình dự đoán để cải thiện độ chính xác của dự án.

#### 0.0.107 Câu hỏi 94:

**Phỏng vấn viên:** Trong dự án thị giác máy tính, bạn đã sử dụng framework hoặc thư viện nào để xây dựng mô hình của mình?

#### 0.0.108 Câu trả lời 94:

Trong dự án phát hiện vật thể trong video, tôi đã sử dụng TensorFlow và Keras để xây dựng và huấn luyện mô hình của mình. TensorFlow cung cấp một cách tiếp cận linh hoạt cho việc xây dựng mạng neural, trong khi Keras là một giao diện lập trình ứng dụng (API) cao cấp giúp việc xây dựng mô hình trở nên đơn giản hơn.

Dưới đây là 6 câu hỏi tiếp theo cùng với câu trả lời:

#### 0.0.109 Câu hỏi 95:

**Phỏng vấn viên:** Trong dự án của bạn, bạn đã đối mặt với vấn đề class imbalance chưa? Nếu có, bạn đã sử dụng các phương pháp nào để xử lý vấn đề này?

#### **0.0.110 Câu trả lời 95:**

Trong dự án phát hiện gian lận trong giao dịch tín dụng, tôi đã gặp vấn đề về class imbalance vì số lượng giao dịch gian lận chỉ chiếm một phần nhỏ so với số lượng giao dịch bình thường. Để xử lý vấn đề này, tôi đã sử dụng kỹ thuật resampling để tạo thêm các mẫu của lớp thiểu số (oversampling) hoặc loại bỏ các mẫu của lớp đa số (undersampling) để cân bằng lại tỷ lệ giữa các lớp.

#### **0.0.111 Câu hỏi 96:**

**Phỏng vấn viên:** Bạn đã từng sử dụng kỹ thuật ensemble learning trong dự án của mình chưa? Nếu có, bạn có thể mô tả cách bạn đã triển khai nó không?

#### **0.0.112 Câu trả lời 96:**

Có, trong dự án phân loại ảnh y tế, tôi đã sử dụng kỹ thuật ensemble learning bằng cách kết hợp nhiều mô hình học máy khác nhau như Random Forest, Gradient Boosting, và Support Vector Machine. Tôi đã sử dụng phương pháp majority voting để quyết định kết quả cuối cùng dựa trên dự đoán của từng mô hình thành viên.

#### **0.0.113 Câu hỏi 97:**

**Phỏng vấn viên:** Trong dự án của bạn, bạn đã xử lý vấn đề của các biến dạng, nhiễu trong dữ liệu hình ảnh như thế nào?

#### **0.0.114 Câu trả lời 97:**

Trong dự án nhận diện biển số xe từ hình ảnh, tôi đã xử lý vấn đề của các biến dạng và nhiễu trong dữ liệu bằng cách thực hiện các bước tiền xử lý như loại bỏ nhiễu, cân bằng độ sáng và độ tương phản của ảnh, cũng như áp dụng các phương pháp augmentation như xoay, phóng to, thu nhỏ và lật ảnh để tạo ra các biến thể mới từ dữ liệu gốc.

#### **0.0.115 Câu hỏi 98:**

**Phỏng vấn viên:** Bạn có kinh nghiệm trong việc sử dụng các mạng neural tái lập (reconstruction neural networks) không? Nếu có, bạn có thể mô tả một ví dụ cụ thể không?

#### **0.0.116 Câu trả lời 98:**

Trong dự án nén ảnh, tôi đã sử dụng một mạng neural tái lập để nén ảnh và sau đó giải nén để tái tạo ảnh gốc. Mô hình này bao gồm một encoder để chuyển đổi ảnh đầu vào thành một biểu diễn gọn gàng, và một decoder để tái tạo lại ảnh gốc từ biểu diễn đó. Kết quả là một mô hình có khả năng nén và giải nén ảnh mà vẫn giữ được chất lượng cao.

#### **0.0.117 Câu hỏi 99:**

**Phỏng vấn viên:** Trong dự án của bạn, bạn đã sử dụng mạng neural tự chú ý (self-attention neural networks) không? Nếu có, bạn có thể mô tả cách bạn đã tích hợp chúng vào dự án không?

**0.0.118 Câu trả lời 99:**

Trong dự án dịch máy, tôi đã sử dụng mạng neural tự chú ý để cải thiện chất lượng của các bản dịch. Mạng này tập trung vào các phần quan trọng của câu nguồn trong quá trình dịch và thực hiện việc dịch dựa trên những phần đó. Tôi đã tích hợp mạng tự chú ý vào mô hình thông qua các lớp self-attention và multi-head attention để học các mối quan hệ phức tạp trong câu.

**0.0.119 Câu hỏi 100:**

**Phỏng vấn viên:** Trong dự án của bạn, bạn đã sử dụng các kỹ thuật tăng cường học tập (reinforcement learning) không? Nếu có, bạn có thể mô tả cách bạn đã áp dụng chúng không?

**0.0.120 Câu trả lời 100:**

Trong dự án xử lý ngôn ngữ tự nhiên, tôi đã sử dụng các kỹ thuật tăng cường học tập để huấn luyện một mô hình sinh văn bản. Cụ thể, tôi đã sử dụng thuật toán REINFORCE để tối ưu hóa các tham số của mô hình dựa trên phản hồi từ một hàm thưởng, mà trong trường hợp này là chất lượng của văn bản được sinh ra. Điều này giúp mô hình tự động học cách tạo ra các văn bản phù hợp với yêu cầu mà không cần sử dụng dữ liệu huấn luyện đã được gán nhãn.